



MINERAÇÃO DE DADOS EM PARTIDAS DE TÊNIS

Introdução à Mineração de Dados · Entrega Parcial · Abril 2026

Júlio Shoji Zotovici Kobayashi - 245708
Lucas Gabriel Hernandez Nogueira - 176761
Yoon Sung Jang - 213087

O que queremos descobrir?



Pergunta central: Quais atributos de uma partida tornam um jogador mais vencedor — e qual deles tem maior impacto sobre o resultado?



O debate do tênis profissional

No alto nível, todos erram pouco. O que diferencia o vencedor não é evitar erros — é produzir mais. Mas o que exatamente?



O papel dos dados

Com estatísticas reais de partidas, podemos comparar todos os atributos e medir qual tem mais poder de separar vencedores de perdedores.



O que queremos entregar

Uma lista ordenada dos atributos por importância, mostrando com evidência empírica o que mais decide uma partida profissional.

O que cada coluna da tabela representa

Cada linha da base é um jogador em uma partida. Cada coluna abaixo é uma característica que o algoritmo vai analisar.

Winners

Numérico discreto

Bolas que terminam o ponto sem o adversário tocar. Mede poder ofensivo.

Aces

Numérico discreto

Saques diretos. Mede domínio absoluto no serviço.

Erros Não Forçados

Numérico discreto

Erros sem pressão do adversário. Ainda separa jogadores.

% 1º Serviço

Numérico contínuo

Percentual de primeiros saques na caixa. Controla o ritmo.

Break Pts Conv.

Numérico contínuo

% de break points aproveitados. Atributo potencialmente decisivo.

Velocidade Saque

Numérico contínuo

Km/h do primeiro saque. Mede poder e pressão no serviço.

Voleis Vencidos

Numérico discreto

Pontos vencidos na rede. Indica estilo agressivo e tático.

Sets Vencidos

Numérico discreto

Número de sets ganhos. Mede domínio geral da partida.

Superfície

Categórico

Saibro, grama ou dura. Muda o perfil do jogo vencedor.

Resultado

Categórico (rótulo)

Vitória ou derrota. É o que o algoritmo vai aprender a prever.

Quantidade de Amostras

Desde 1968: mais de 600 mil partidas

Contraponto: somente partidas a partir de 1991 contam com dados completos. Rankings aparecem de forma consistente desde 1985.

Intervalo de tempo de coleta dos dados

De 1968 até os dias atuais

É atualizado com frequência, as vezes até semanalmente

Outliers

Algumas inconsistências

Alguns dados como partidas com menos de 20 minutos e o perdedor ter mais de 60% dos pontos totais, o que sugerem erros nos registros

Por que usaremos Classificação?

Classificação é a tarefa certa quando se sabe a resposta para os dados antigos e quer que o algoritmo **aprenda a prever a resposta para dados novos**.

No nosso caso: temos partidas com resultado conhecido (vitória/derrota) e queremos aprender quais estatísticas levam a cada resultado.

E o Agrupamento (K-means)?

Pretendemos utilizar como etapa exploratória para descobrir perfis naturais de partidas, como jogo de serviço ou jogo de fundo. Esses perfis podem virar um atributo a mais para o classificador.

Estatísticas
da partida

Algoritmo
aprende

Prevê:
Vitória/Derrota

Importância
dos atributos

Quais algoritmos pretendemos aplicar



Árvore de Decisão

Principal vantagem:

Gera regras legíveis em português e mostra diretamente quais atributos foram mais usados.



RNA — Rede Neural

Principal vantagem:

Captura relações escondidas entre atributos — por exemplo, winners na grama podem ter peso diferente de winners no saibro.

Passo a passo do que faremos

01

Coleta e entendimento

Carregar a base e entender partidas, colunas e significados.

02

Limpeza dos dados

Tratar ausentes, erros de registro e duplicados.

03

Transformação

Converter texto em número e normalizar atributos para mesma escala.

04

Exploração com K-means

Descobrir perfis táticos naturais sem usar o rótulo.

05

Treino e Teste

Separar 80% para treino e 20% para teste.

06

Classificação

Treinar Árvore de Decisão e MLP; comparar métricas.

07

Importância dos atributos

Extrair da árvore quais atributos foram mais usados.

O que a mineração vai nos revelar



Ao final do projeto, teremos uma resposta baseada em dados para a grande pergunta do tênis profissional:

“O que estatisticamente separa vencedores de perdedores — e qual atributo pesa mais?”



1

Ranking de importância

Lista dos 10 atributos ordenada pelo impacto na vitória.



2

Regras interpretáveis

Frases do tipo: “Se break points > 45% e winners > 28 → vitória.”



3

Modelo preditivo

Algoritmo capaz de prever o resultado das estatísticas.



4

Perfis de vencedor

Quais estilos de jogo têm maior taxa de vitória.

De onde vêm os dados?



Nome da base: Match Charting Project (MCP)

Fonte / Link: https://github.com/JeffSackmann/tennis_MatchChartingProject

Qtd. de amostras: 180.000

Intervalo de tempo: 1968-2026

Dados faltantes: Aces, Double Faults, Break Points Saved, Rankings, Dados do Atleta

Valores discrepantes: Partidas com duração menor que 20 minutos, 60% do total de pontos totais ao perderdor

Variável alvo: Resultado da partida (Vitória / Derrota) — binário